

0 ALGORISMO K-NN

0 K-NN é um algoritmo supervisionado de aprendizagem, desenvolvido nos anos '50, usado principalmente para classificação (imagens, texto, diagnóstico), mas também para regressão, agregação de informação em Redes Neurais e anomaly detection. (Ainda Hoje)

Porque é interessante

- é útil
- permite aprender vários dos princípios e problemas do Aprendizado automático.
- É matematicamente interessante e bastante simples de permitir demonstrações analíticas.

"supervisionado": O algoritmo é instruído sobre o que os dados são. Exemplo: imagens de treinamento estão com etiquetas: 5 "é um cinco."

ALGORISMO

Suponha que temos n copias $(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n)$. 'n' numero de dados total $X_i \in \mathbb{R}^d$ (é um vetor em dimensão d), $Y_i \in \{\text{classe 1, classe 2, } \dots, \text{classe } m\}$.

Exemplo: Temos $n=60'000$ imagens de dígitos de 0 a 9 em escala de cinzentos de 0 a 255

$\leadsto i \in \{1, \dots, 60'000 = n\}$, $d = 255$ e $Y_i \in \{0, \dots, 9\}$.

X_i é um vetor $X_i^0, X_i^1, X_i^2, \dots, X_i^{255}$ chamado "features vector". Cada componente X_i^x é uma feature.

Pelo momento simplificamos e consideramos só 'classe 1' e 'classe 7'.

Definimo uma distância entre X_i e X_j : $d(X_i, X_j)$, tipicamente $d(\cdot, \cdot)$

é distância euclídea $d: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$, ou seja.


$$d(X_i, X_j) = \left((X_i^0 - X_j^0)^2 + (X_i^1 - X_j^1)^2 + \dots + (X_i^{255} - X_j^{255})^2 \right)^{1/2}$$

Como funciona? Dado um dado desconhecido X_{new} , não conhecemos a sua etiqueta Y_{new} e queremos classificar-la, ou seja o que X_{new} é.

O algoritmo calcula todas as distâncias $d(x, X^1), d(x, X^2), \dots, d(x, X^{60000})$ e classifica $x = 0$ se nos primeiros K -vizinhos a maioria é 0, no caso contrário classifica 1. K é o parâmetro a definir.

I problema: como definimos K ? $K=1$ ou 3 ou 5?

II problema: As etiquetas são noisy (erros, alguns 0 tem etiqueta 1 o viceversa)



$K=1 \rightarrow \bar{e}$ um 7

$K=3 \rightarrow \bar{e}$ um 1

$K=5 \rightarrow \bar{e}$ um 7

Problema I


O 7 mais perto é um 1

1

← Problema II


III problema: Os dados são todos representados poritariamente? (skewed data)

Se o dado não são balanceados, teremos tendencialmente maioria de votos das classe mais representada.




Porque k demais pequena não é bom?

O impacto do ruído é muito forte



Porque k demais grande não é bom?

Nos votos começam a votar vizinhos demais distante.



Vamos testar o algoritmo; mantendo a mesma n_{220} $\frac{\# \text{ test data}}{\# \text{ trainin data}}$

test 801, training 134

k = 1	Accuracy: 73.88%
k = 3	Accuracy: 79.1%
k = 5	Accuracy: 85.07%
k = 7	Accuracy: 85.07%
k = 9	Accuracy: 82.09%
k = 11	Accuracy: 81.34%
k = 15	Accuracy: 82.09%
k = 21	Accuracy: 79.85%
k = 31	Accuracy: 79.1%
k = 51	Accuracy: 75.37%
k = 101	Accuracy: 67.16%
k = 201	Accuracy: 56.72%
k = 401	Accuracy: 36.57%
k = 801	Accuracy: 11.19%

Total Duration: 0.274 seconds

1

test 6000, training 1000

k = 1	Accuracy: 79.5%
k = 3	Accuracy: 88.2%
k = 5	Accuracy: 90.8%
k = 7	Accuracy: 91.1%
k = 9	Accuracy: 91.3%
k = 11	Accuracy: 90.7%
k = 15	Accuracy: 89.7%
k = 21	Accuracy: 88.6%
k = 31	Accuracy: 87.9%
k = 51	Accuracy: 86.2%
k = 101	Accuracy: 82.6%
k = 201	Accuracy: 77.9%
k = 401	Accuracy: 71.7%
k = 801	Accuracy: 62.2%

Total Duration: 1.742 seconds

2

test 60.000, training 1000

k = 1	Accuracy: 85.5%
k = 3	Accuracy: 94.06%
k = 5	Accuracy: 96.62%
k = 7	Accuracy: 96.85%
k = 9	Accuracy: 96.77%
k = 11	Accuracy: 96.7%
k = 15	Accuracy: 96.36%
k = 21	Accuracy: 96.27%
k = 31	Accuracy: 95.79%
k = 51	Accuracy: 95.26%
k = 101	Accuracy: 94.36%
k = 201	Accuracy: 92.84%
k = 401	Accuracy: 91.09%
k = 801	Accuracy: 88.5%

Total Duration: 159.667 seconds

3

A) Posso encontrar numericamente o k ótimo;

B) O ruído é suavizado aumentando o número de elementos, bem filtrado com $k=7$


C) A Precisão do Algoritmo cresce com N , mas o tempo computacional aumenta não linearmente

$n_2 \approx 10 n_1$ e $T_{n_2}/T_{n_1} \approx 6,35$. mas $n_3 \approx 10 n_2$ e $T_{n_3}/T_{n_1} \approx 94,65$

Problem = 4

Medição de Dimensionalidade


Em princípio seria possível particionar o espaço e considerar só as células com fronteiras em comum a célula de X , quando perto de uma fronteira



Mas a medição de Dimensionalidade impede isso:

A) • $d=1$ $3^d - 1 = 2$

• $d=2$ $3^d - 1 = 8$



• $d=3$ $3^d - 1 = 27$

• $d=784$ $3^{784} - 1 \approx 1 \times 10^{374}!$

B) Em dimensão alta todos os pontos estão perto de fronteiras:

$V^d = 1 \times 1 \times \dots \times 1^d$, tiramos a 1% de parte exterior do volume e calculamos $V^d - 1\%$

• $d=2$, $\tilde{V}^d \approx 0,98^2 = 96\%$

• $d=3$, $\tilde{V}^d \approx 0,98^3 = 94\%$


• $d=100$, $\tilde{V}^d \approx 0,98^{100} = 13\%$

• $d=784$, $\tilde{V}^d \approx 0,98^{784} = 0,00000013$

$\leadsto$ A ideia não funciona.

Paralleliza 3o

○ K-NN Brute force é altamente paralelo



Resolheu todas as computações.